

Statistique appliquée à la recherche scientifique

Formation doctorale

Pr. El Mahdi Mouloua

16 mai 2026

Statistique descriptive bivariée

Dans plusieurs phénomènes on peut envisager pour une même population, l'étude de deux ou plusieurs caractères en même temps.

1. Étudier si l'augmentation de la dose d'un médicament améliore la réponse thérapeutique.
 - ▶ X : nombre de cigarettes/jour.
 - ▶ Y : capacité pulmonaire (L).
2. Étudier l'impact du tabac sur la fonction respiratoire.
 - ▶ X : dose du médicament (mg).
 - ▶ Y : diminution de la douleur (%).

Pour une population Il y'a plusieurs objectifs pour réaliser ces études tels que :

1. Étendre les notions de la statistique univariée à la statistique bivariée.
2. La mise en évidence d'un lien ou d'une absence de lien entre les deux variables étudiées.
3. Caractériser et commenter les relations qui peuvent exister entre deux séries d'observations considérées simultanément (sens, intensité).

Distribution statistique à deux variables

On appelle distribution statistique à deux variables X et Y l'ensemble :

$$\{(x_i, y_j, n_{ij}), i = 1, \dots, p, j = 1, \dots, k\}.$$

Cette distribution est présentée par un

Tableau de contingence.

ou encore

Tableau croisé,

on dit également parfois

Distribution conjointe des effectifs.

Distribution conjointe

$X \backslash Y$	y_1	$\dots$	y_j	$\dots$	y_l	Total
x_1	n_{11}	$\dots$	n_{1j}	$\dots$	n_{1l}	$n_{1\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_{i1}	$\dots$	n_{ij}	$\dots$	n_{il}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_h	n_{h1}	$\dots$	n_{hj}	$\dots$	n_{hl}	$n_{h\bullet}$
Total	$n_{\bullet 1}$	$\dots$	$n_{\bullet j}$	$\dots$	$n_{\bullet l}$	n

Effectif conjoint n_{ij} :

Nombre d'individus ayant la modalité x_i de X et la modalité y_j de Y à la fois.

Effectif marginal ligne $n_{i\bullet}$:

Nombre d'individus ayant la modalité x_i de X .

Effectif marginal colonne $n_{\bullet j}$:

Nombre d'individus ayant la modalité y_j de Y .

Effectifs marginaux : $n_{i\bullet} = \sum_{j=1}^l n_{ij}$ et $n_{\bullet j} = \sum_{i=1}^h n_{ij}$ pour tout i et tout j .

Distribution conjointe

$X \backslash Y$	y_1	$\dots$	y_j	$\dots$	y_l	Total
x_1	f_{11}	$\dots$	f_{1j}	$\dots$	f_{1l}	$f_{1\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	f_{i1}	$\dots$	f_{ij}	$\dots$	f_{il}	$f_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_h	f_{h1}	$\dots$	f_{hj}	$\dots$	f_{hl}	$f_{h\bullet}$
Total	$f_{\bullet 1}$	$\dots$	$f_{\bullet j}$	$\dots$	$f_{\bullet l}$	1

Fréquence conjointe f_{ij} :

Proportion d'individus ayant la modalité x_i de X et la modalité y_j de Y à la fois.

Fréquence marginale ligne $f_{i\bullet}$:

Proportion d'individus ayant la modalité x_i de X .

Fréquence marginale colonne $f_{\bullet j}$:

Proportion d'individus ayant la modalité y_j de Y .

Propriétés :


- $0 \leq f_{ij} \leq 1$ pour tout i, j .
- $\sum_{j=1}^l f_{ij} = f_{i\bullet}$ pour tout i .
- $\sum_{i=1}^h f_{ij} = f_{\bullet j}$ pour tout j .
- $\sum_{i=1}^h \sum_{j=1}^l f_{ij} = 1$.

Fréquences marginales : $f_{i\bullet} = \sum_{j=1}^l f_{ij}$ et $f_{\bullet j} = \sum_{i=1}^h f_{ij}$ pour tout i et tout j .

Représentation graphique de deux variables

Exemple 1 Le Tableau ci-dessous contient le poids Y et la taille X de 20 individus. Le nuage de points est représenté dans la figure ci-dessous.

y_i	60	61	64	67	68	69	70	70	72	73	75	76	78	80	85	90	96	96	98	101
x_i	155	162	157	170	164	162	169	170	178	173	180	175	173	175	179	175	180	185	189	187



Représentation graphique de deux variables

Exemple 1 La distribution conjointe des variables X et Y est donnée par :

$\begin{array}{c} X \\ \backslash \\ Y \end{array}$	[155, 165[	[165, 175[	[175, 185[	[185, 195[	Total
[60, 70[	5	1	0	0	6
[70, 80[	0	4	3	0	7
[80, 90[	0	0	2	0	2
[90, 105[	0	0	2	3	5
Total	5	5	7	3	20

Représentation graphique de deux variables

Exemple 2 On désire étudier la répartition de 17500 jeunes salariés selon l'âge et le salaire en MDH.

- ▶ X : la variable désignant l'âge
- ▶ Y : la variable désignant le salaire mensuel en MDH

$X \backslash Y$	$[5, 6[$	$[6, 7[$	$[7, 8[$	$n_{i\bullet}$
$[20, 22[$	1200	500	100	1800
$[22, 24[$	2500	3500	600	6600
$[24, 26[$	1800	5000	2300	9100
$n_{\bullet j}$	5500	9000	3000	17500

Distribution marginale

Les k couples $(x_i, n_{i\bullet})$ forment la **distribution marginale** de la variable X .

Les l couples $(y_j, n_{\bullet j})$ forment la **distribution marginale** de la variable Y .

Les distributions marginales peuvent également être exprimées sous forme de fréquences :

$$f_{i\bullet} = \frac{n_{i\bullet}}{n} \quad \text{et} \quad f_{\bullet j} = \frac{n_{\bullet j}}{n}$$

- ▶ $f_{i\bullet}$: fréquence marginale de la modalité x_i .
- ▶ $f_{\bullet j}$: fréquence marginale de la modalité y_j .
- ▶ n : effectif total.

Distribution marginale

Distribution marginale de X

X	$n_{i\bullet}$	$f_{i\bullet}$
$[20, 22[$	1800	0.10
$[22, 24[$	6600	0.37
$[24, 26[$	9100	0.52
n	17500	1

$$n_{1\bullet} = 1800$$

1800 salariés ont un âge compris entre 20 et 22 ans.

$$f_{2\bullet} = 0.37$$

37% des salariés sont âgés de 22 à 24 ans.

Distribution marginale de Y

Y	$n_{\bullet j}$	$f_{\bullet j}$
$[5, 6[$	5500	0.31
$[6, 7[$	9000	0.51
$[7, 8[$	3000	0.17
n	17500	1

$$n_{\bullet 1} = 5500$$

5500 salariés gagnent entre 5000 et 6000 DH.

$$f_{\bullet 2} = 0.51$$

51% des salariés ont un salaire compris entre 6000 et 7000 DH.

Distribution conditionnelle

La **distribution conditionnelle** de la variable $\mathbf{Y}$, pour $\mathbf{X} = \mathbf{x}_i$ fixé, est la distribution statistique des valeurs de Y obtenue en se limitant aux individus pour lesquels X est égal à x_i .

$Y/X = x_i$	y_1	$\cdots$	y_j	$\cdots$	y_l	Total
Effectif	n_{i1}	$\cdots$	n_{ij}	$\cdots$	n_{il}	$n_{i\bullet}$

Cette distribution des $n_{i\bullet}$ observations satisfaisant à la condition $X = x_i$ est présentée sous la forme de fréquences conditionnelles :

$$f_{j/i} = \frac{n_{ij}}{n_{i\bullet}} \quad \text{avec} \quad \sum_{j=1}^l f_{j/i} = 1$$

$Y/X = x_i$	y_1	$\cdots$	y_j	$\cdots$	y_l	Total
Fréquence	$f_{1/i}$	$\cdots$	$f_{j/i}$	$\cdots$	$f_{l/i}$	1

Distribution conditionnelle

La **distribution conditionnelle** de la variable $\mathbf{X}$, pour $\mathbf{Y} = \mathbf{y}_j$ fixé, est la distribution statistique des valeurs de X obtenue en se limitant aux individus pour lesquels Y est égal à y_j .

$X/Y = y_j$	x_1	$\cdots$	x_i	$\cdots$	x_k	Total
Effectif	n_{1j}	$\cdots$	n_{ij}	$\cdots$	n_{kj}	$n_{\bullet j}$

Cette distribution des $n_{\bullet j}$ observations satisfaisant à la condition $Y = y_j$ est présentée sous la forme de fréquences conditionnelles :

$$f_{i/j} = \frac{n_{ij}}{n_{\bullet j}} \quad \text{avec} \quad \sum_{i=1}^k f_{i/j} = 1$$

$X/Y = y_j$	x_1	$\cdots$	x_i	$\cdots$	x_k	Total
Fréquence	$f_{1/j}$	$\cdots$	$f_{i/j}$	$\cdots$	$f_{k/j}$	1

Distribution conditionnelle

Exemple

Distribution conditionnelle du salaire y_j sachant que l'âge est entre 22 et 24 ans.

Y	$[22, 24[$	$f_{j/2}$
$[5, 6[$	2500	0.38
$[6, 7[$	3500	0.53
$[7, 8[$	600	0.09
$n_{2\bullet}$	6600	1

Parmi les 6600 salariés qui ont un âge compris entre 22 et 24 ans, 2500 touchent un salaire entre 5000 et 6000 DH.

$$f_{j=1/i=2} = f_{1/2} = \frac{2500}{6600} = 0.378$$

37.8% des salariés qui ont un âge compris entre 22 et 24 ans touchent un salaire entre 5000 et 6000 DH.

Distribution conditionnelle

1. Si les observations se portent simultanément sur deux variables, il est souvent fréquent de présenter les données dans un tableau donnant l'ensemble des distributions conditionnelles de Y , appelé **tableau de profils en ligne**.

$X \backslash Y$	[5, 6[	[6, 7[	[7, 8[	<i>Total</i>
[20, 22[	0.667	0.278	0.055	1
[22, 24[	0.379	0.530	0.091	1
[24, 26[	0.198	0.549	0.253	1
<i>Distribution marginale de Y</i>	5500	9000	3000	17500

2. Bien évidemment, on définit d'une façon symétrique le **tableau des profils en colonne**

$X \backslash Y$	[5, 6[	[6, 7[	[7, 8[	<i>Distribution marginale de X</i>
[20, 22[	0.218	0.056	0.033	1800
[22, 24[	0.455	0.389	0.200	6600
[24, 26[	0.327	0.556	0.767	9100
<i>Total</i>	1	1	1	17500

Si tous les profils en colonne du tableau précédent sont identiques, cela signifie que la distribution de la variable X ne dépend pas de la variable Y , on dit alors que les variables X et Y sont statistiquement indépendantes dans l'ensemble des n individus considérés, et dans ce cas toutes les distributions conditionnelles de X sont identiques à la distribution marginale de X .

Comparaison des distributions

Type	Définition	Question scientifique	Ce qu'on étudie	Intérêt scientifique
Distribution marginale	$f_X(x)$ ou $f_Y(y)$	Comment se comporte une variable seule ?	Analyse individuelle d'une variable	Décrire une variable : moyenne, dispersion, asymétrie, histogramme, etc.
Distribution conjointe	$f_{X,Y}(x, y)$	Comment deux variables évoluent-elles ensemble ?	Dépendance, covariance, corrélation	Étudier les relations et interactions entre variables
Distribution conditionnelle	$f_{Y X}(y x)$	Comment se comporte Y lorsque X est fixé ?	Influence d'une variable sur une autre	Analyser un effet, prédire et construire des modèles

Dépendance et indépendance statistique

On peut écrire en termes d'effectifs ou de fréquences ce que signifie l'indépendance statistique entre X et Y ; pour tout couple (i, j) :

$$f_{i/j} = f_{i\bullet} \iff \frac{f_{ij}}{f_{\bullet j}} = f_{i\bullet} \iff f_{ij} = f_{i\bullet} \cdot f_{\bullet j} \iff n_{ij} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}$$

Caractéristiques marginales : Variable X

1. Moyenne marginale :

$$\bar{x} = \frac{1}{n} \sum_i n_{i\bullet} x_i = \sum_i f_{i\bullet} x_i$$

2. Variance marginale :

$$\begin{aligned} V(X) &= \frac{1}{n} \sum_i n_{i\bullet} (x_i - \bar{x})^2 \\ &= \sum_i f_{i\bullet} (x_i - \bar{x})^2 \end{aligned}$$

3. Théorème de Koenig :

$$V(X) = \frac{1}{n} \sum_i n_{i\bullet} x_i^2 - \bar{x}^2$$

Caractéristiques marginales : Variable Y

1. Moyenne marginale :

$$\bar{y} = \frac{1}{n} \sum_j n_{\bullet j} y_j = \sum_j f_{\bullet j} y_j$$

2. Variance marginale :

$$\begin{aligned} V(Y) &= \frac{1}{n} \sum_j n_{\bullet j} (y_j - \bar{y})^2 \\ &= \sum_j f_{\bullet j} (y_j - \bar{y})^2 \end{aligned}$$

3. Théorème de Koenig :

$$V(Y) = \frac{1}{n} \sum_j n_{\bullet j} y_j^2 - \bar{y}^2$$

1. **Moyenne conditionnelle de X si $Y = y_j$:**

$$\bar{x}_j = \frac{1}{n_{\bullet j}} \sum_i n_{ij} x_i = \sum_i f_{i/j} x_i$$

2. **Variance conditionnelle de X si $Y = y_j$:**

$$V_j(X) = \frac{1}{n_{\bullet j}} \sum_i n_{ij} (x_i - \bar{x}_j)^2 = \sum_i f_{i/j} (x_i - \bar{x}_j)^2$$

1. **Moyenne conditionnelle de Y si $X = x_i$:**

$$\bar{y}_i = \frac{1}{n_{i\bullet}} \sum_j n_{ij} y_j = \sum_j f_{j/i} y_j$$

2. **Variance conditionnelle de Y si $X = x_i$:**

$$V_i(Y) = \frac{1}{n_{i\bullet}} \sum_j n_{ij} (y_j - \bar{y}_i)^2 = \sum_j f_{j/i} (y_j - \bar{y}_i)^2$$

Motivation

Une équipe de recherche en biologie souhaite étudier la relation entre la **dose** d'un médicament administré et le **taux de réponse thérapeutique** observé chez des patients.

Les données recueillies sur 10 patients sont les suivantes :

Patient	1	2	3	4	5	6	7	8	9	10
Dose (X)	2	5	1	6	5	1	6	3	4	7
Réponse thérapeutique (Y)	50	57	41	54	54	38	63	48	59	65


Questions :

- ▶ Existe-t-il une liaison statistique entre la dose administrée et la réponse thérapeutique ?
- ▶ Peut-on modéliser cette relation par une fonction mathématique :

$$Y = f(X)$$

Représentation graphique


Une **représentation graphique** ou **nuage de points** est l'ensemble des N points M_i de coordonnées (x_i, y_i) , avec $i \in \{1, \dots, N\}$.



- Le nuage de points permet d'apprécier l'existence ou non d'une éventuelle liaison.


Représentation graphique

Une **représentation graphique** ou **nuage de points** est l'ensemble des N points M_i de coordonnées (x_i, y_i) , avec $i \in \{1, \dots, N\}$.




- Le nuage de points permet d'apprécier l'existence ou non d'une éventuelle liaison.
- Il permet également de déterminer la forme de la liaison.

Analyse graphique




- Il existe une liaison entre les deux variables : lorsque la dose du médicament varie, la réponse thérapeutique tend également à varier.

Analyse graphique



- ▶ Il existe une liaison entre les deux variables : lorsque la dose du médicament varie, la réponse thérapeutique tend également à varier.
- ▶ Cette liaison semble approximativement linéaire : les points du nuage sont globalement proches d'une droite.

Analyse graphique



- ▶ Il existe une liaison entre les deux variables : lorsque la dose du médicament varie, la réponse thérapeutique tend également à varier.
- ▶ Cette liaison semble approximativement linéaire : les points du nuage sont globalement proches d'une droite.
- ▶ Cette liaison est positive : plus la dose administrée augmente, plus la réponse thérapeutique tend à augmenter.

Pour cette étude biologique, le nuage de points montre que les variables ont tendance à covarier (varier simultanément).

Lorsque la dose du médicament augmente, la réponse thérapeutique tend également à augmenter.

⇒ Construction d'un indicateur permettant de mesurer la variabilité conjointe des deux variables.

- ▶ Mesure descriptive de la relation entre les deux variables ;
- ▶ Mesure les fluctuations simultanées de chaque variable par rapport à sa moyenne.

Covariance

La **covariance** : est la moyenne des produits des écarts à la moyenne des variables X et Y .

$$\text{Cov}(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{N}$$

$$\text{Cov}(X, Y) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x} \bar{y}$$

$\text{Cov}(X, Y) = \text{moyenne du produit } XY - \text{produit des moyennes de } X \text{ et } Y$

Propriétés :

1. $\text{Cov}(X, Y) > 0 \iff X \text{ et } Y \text{ varient dans le même sens}$

Propriétés :

1. $\text{Cov}(X, Y) > 0 \iff X \text{ et } Y \text{ varient dans le même sens}$
2. $\text{Cov}(X, Y) < 0 \iff X \text{ et } Y \text{ varient en sens opposé}$

Propriétés :

1. $\text{Cov}(X, Y) > 0 \iff X \text{ et } Y \text{ varient dans le même sens}$
2. $\text{Cov}(X, Y) < 0 \iff X \text{ et } Y \text{ varient en sens opposé}$
3. $\text{Cov}(X, Y) = \text{Cov}(Y, X)$

Propriétés :

1. $\text{Cov}(X, Y) > 0 \iff X \text{ et } Y \text{ varient dans le même sens}$
2. $\text{Cov}(X, Y) < 0 \iff X \text{ et } Y \text{ varient en sens opposé}$
3. $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
4. $\text{Cov}(aX + b, cY + d) = ac \text{ Cov}(X, Y)$

Propriétés :

1. $\text{Cov}(X, Y) > 0 \iff X \text{ et } Y \text{ varient dans le même sens}$
2. $\text{Cov}(X, Y) < 0 \iff X \text{ et } Y \text{ varient en sens opposé}$
3. $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
4. $\text{Cov}(aX + b, cY + d) = ac \text{ Cov}(X, Y)$
5. $X \text{ et } Y \text{ indépendantes} \Rightarrow \text{Cov}(X, Y) = 0$ La réciproque est généralement fausse.

Covariance

On veut démontrer que : X et Y sont indépendantes $\Rightarrow \text{Cov}(X, Y) = 0$

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

$$= \mathbb{E}[XY - X\mathbb{E}(Y) - Y\mathbb{E}(X) + \mathbb{E}(X)\mathbb{E}(Y)]$$

$$= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) - \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y)$$

Donc :

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

Ainsi :

$$\text{Cov}(X, Y) = 0$$

Covariance

Calcul de la covariance :

$$\text{Cov}(X, Y) = \frac{1}{N} \sum_{i=1}^{10} x_i y_i - \bar{x} \bar{y}$$

$$\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = 4$$

$$\bar{y} = \frac{1}{10} \sum_{i=1}^{10} y_i = 52.9$$

$$\text{Cov}(X, Y) = \frac{2271}{10} - (4)(52.9) = 15.5 > 0$$

Patient	X	Y	XY
1	2	50	100
2	5	57	285
3	1	41	41
4	6	54	324
5	5	54	270
6	1	38	38
7	6	63	378
8	3	48	144
9	4	59	236
10	7	65	455
Total	40	529	2271

X : Dose du médicament (mg)

Y : Réponse thérapeutique (%)

Interprétation :

Une augmentation de la dose du médicament tend à être associée à une augmentation de la réponse thérapeutique.

Covariance : avantages et limites en recherche scientifique

► Avantages

- Permet de mesurer le sens de variation entre deux variables.
- Indique si deux phénomènes évoluent ensemble ou en sens opposé.
- Joue un rôle fondamental en régression linéaire et en corrélation.
- Utilisée dans plusieurs domaines : économie, médecine, physique, intelligence artificielle, réseaux de neurones, etc.
- Permet d'identifier des relations potentielles entre variables expérimentales.

► Limites

- La covariance dépend des unités de mesure.
- Sa valeur est difficile à interpréter directement.
- Une covariance nulle n'implique pas toujours l'indépendance.
- Sensible aux valeurs extrêmes (outliers).

Coefficient de corrélation linéaire

Soient deux variables statistiques X et Y .

Le coefficient de corrélation linéaire, noté ρ , est défini par :

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

Le coefficient de corrélation linéaire permet :

- ▶ d'évaluer le sens de la relation linéaire entre X et Y ;
- ▶ de mesurer l'intensité de cette relation ;
- ▶ de quantifier le degré de dépendance linéaire entre les deux variables.

L'intérêt de la corrélation réside dans sa capacité à valider des hypothèses de recherche et à orienter les modèles prédictifs avant d'engager des analyses plus lourdes (comme les régressions multiples ou le Machine Learning).

Propriétés :

1. $-1 \leq \rho \leq 1$
2. Si ρ est proche de -1 : il existe une forte corrélation négative.
3. Si ρ est proche de 1 : il existe une forte corrélation positive.
4. Si $\rho < 0$ et proche de 0 : il existe une faible corrélation négative.
5. Si $\rho > 0$ et proche de 0 : il existe une faible corrélation positive.
6. Si $\rho = 0$: les variables X et Y ne sont pas linéairement corrélées.

Coefficient de corrélation linéaire

Valeurs de ρ pour l'interprétation :



$$0 \leq |\rho| < 0.40$$

faible ou quasi absence de corrélation.



$$0.40 \leq |\rho| < 0.60$$

corrélation moyenne.



$$0.60 \leq |\rho| < 0.80$$

bonne corrélation.



$$0.80 \leq |\rho| \leq 1$$

corrélation élevée.

Coefficient de corrélation linéaire

Règle d'or pour le chercheur

Ces seuils sont des **repères conventionnels**, pas des lois absolues. L'interprétation d'un coefficient de corrélation dépend toujours de trois critères indissociables :

1. **Le domaine scientifique** : La tolérance au bruit (dispersion) n'est pas la même en physique quantique ou en ingénierie (où un $|\rho| > 0.90$ est souvent requis) qu'en sociologie ou psychologie, où un $|\rho| = 0.30$ révèle déjà un effet structurel majeur et publiable.
2. **La taille de l'échantillon (n)** : Un coefficient faible ($|\rho| = 0.25$) calculé sur 10 000 individus possède une puissance et une robustesse scientifique bien supérieures à un coefficient élevé ($|\rho| = 0.85$) obtenu sur un échantillon de fortune de seulement 8 individus.
3. **La p-value (Significativité statistique)** : La valeur brute de $|\rho|$ ne possède aucune validité méthodologique sans un test d'hypothèse associé (test de nullité de la corrélation). Ce test garantit formellement que l'association observée n'est pas le simple fruit du hasard de l'échantillonnage.

Coefficient de corrélation et tests d'hypothèses

La p -value et le test d'hypothèse sont les verrous de sécurité mathématiques qui permettent d'affirmer : « **Mon résultat est une découverte scientifique, pas un coup de chance.** »

Un test d'hypothèse est une procédure de décision quantitative. Face à vos données (par exemple, une corrélation observée de $\rho = 0.40$ entre deux variables), le chercheur doit arbitrer entre deux scénarios concurrents :

H_0 (L'Hypothèse Nulle) : Le scénario du sceptique. Il n'y a aucun lien réel entre les deux variables dans la population générale. La corrélation que vous observez sur votre petit échantillon est un pur hasard (un artefact d'échantillonnage).

H_1 (L'Hypothèse Alternative) : Votre hypothèse de recherche. Il existe un lien réel et structurel entre les deux variables.

Le but du test statistique est de mesurer si vos données expérimentales sont suffisamment extrêmes pour rejeter le scénario du sceptique (H_0).

Coefficient de corrélation linéaire

Calcul de ρ :

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

$$\sigma(X) = \sqrt{\frac{1}{N} \sum_{i=1}^{10} x_i^2 - \bar{x}^2} = 2.049$$


$$\sigma(Y) = \sqrt{\frac{1}{N} \sum_{i=1}^{10} y_i^2 - \bar{y}^2} = 8.37$$

$$\rho = \frac{15.5}{2.049 \times 8.37} = 0.903$$

ρ proche de 1 $\Rightarrow$ forte corrélation positive.

S	X	Y	XY	X ²	Y ²
1	2	50	100	4	2500
2	5	57	285	25	3249
3	1	41	41	1	1681
4	6	54	324	36	2916
5	5	54	270	25	2916
6	1	38	38	1	1444
7	6	63	378	36	3969
8	3	48	144	9	2304
9	4	59	236	16	3481
10	7	65	455	49	4225
Total	40	529	2271	202	28685

Motivation



- ▶ Le nuage de points présente une forme globalement allongée.
- ▶ Une droite peut alors être utilisée pour représenter au mieux la tendance générale du nuage de points.
- ▶ L'objectif est de déterminer une droite passant au plus près de l'ensemble des observations.

Régression linéaire simple


Meilleur droite au sens des moindres carrés

Supposons qu'on cherche à ajuster une droite d'équation réduite $y = ax + b$.

Pour une modalité x_i . La droite prédit $\hat{y}_i = ax_i + b$.

On définit l'erreur $e_i = y_i - \hat{y}_i$.

Interprétation géométrique



Nous allons déterminer la **meilleure droite au sens des moindres carrés**, c'est à dire telle que : $\sum_{i=1}^n |M_i H_i|^2$ soit minimum.

Méthode des moindres carrés

On cherche une droite (D) d'équation réduite $y = ax + b$ telle que la fonction :

$U(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2$ soit minimum.

$$U(a, b) = \sum_{i=1}^n (y_i - ax_i)^2 - 2b \sum_{i=1}^n (y_i - ax_i) + nb^2$$

Le minimum est obtenu lorsque :

$$\frac{\partial U}{\partial b}(a, \hat{b}) = 0$$

Donc :

$$-2 \left(\sum_{i=1}^n (y_i - ax_i) - n\hat{b} \right) = 0$$

On obtient alors :

$$\hat{b} = \frac{1}{n} \sum_{i=1}^n (y_i - ax_i) = \bar{y} - a\bar{x}$$

Le point $(\bar{x}, \bar{y})$ appartient à la droite des moindres carrés ; on l'appelle le centre de gravité ou le point moyen du nuage.

Méthode des moindres carrés

Maintenant on détermine le minimum de $U(a, \hat{b})$ relativement à a .

$$\begin{aligned} U(a, \hat{b}) &= \sum_{i=1}^n ((y_i - \bar{y}) - a(x_i - \bar{x}))^2 \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - 2a \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) + a^2 \sum_{i=1}^n (x_i - \bar{x})^2 \end{aligned}$$

On peut écrire :

$$U(a, \hat{b}) = n (a^2 \text{var}(X) - 2a \text{cov}(X, Y) + \text{var}(Y))$$

Comme le coefficient de a^2 est positif ou nul, ce trinôme admet un minimum pour :

$$\hat{a} = \frac{\text{cov}(X, Y)}{\text{var}(X)}$$

Ainsi :

$$(\hat{a}, \hat{b}) \quad \text{avec} \quad \hat{b} = \bar{y} - \hat{a}\bar{x}$$

réalise le minimum de la fonction U .

L'équation de la droite des moindres carrés

$$y = \hat{a}x + \hat{b}$$

soit :

$$y - \bar{y} = \frac{\text{cov}(X, Y)}{\text{var}(X)}(x - \bar{x})$$

Pour tout $i \in \{1, \dots, n\}$, on pose :

$$\hat{y}_i = \hat{a}x_i + \hat{b}$$

où $\hat{y}_i$ représente la valeur estimée de Y par la droite des moindres carrés lorsque $X = x_i$.

Interprétation du coefficient de corrélation linéaire

En remplaçant a par son estimation $\hat{a}$, on obtient :

$$\begin{aligned}U(a, \hat{b}) &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 = n \left(\frac{(\text{cov}(X, Y))^2}{\text{var}(X)} - 2 \frac{(\text{cov}(X, Y))^2}{\text{var}(X)} + \text{var}(Y) \right) \\&= n \left(\text{var}(Y) - \frac{(\text{cov}(X, Y))^2}{\text{var}(X)} \right)\end{aligned}$$

et comme :

$$r^2 = \frac{(\text{cov}(X, Y))^2}{\text{var}(X) \cdot \text{var}(Y)}$$

on a :

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = n \text{var}(Y) (1 - r^2) \iff \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \bar{y})^2 (1 - r^2)$$

ce qui implique :

$$1 - r^2 \geq 0 \quad \Rightarrow \quad |r| \leq +1 \quad \text{et} \quad |\text{cov}(X, Y)| \leq \sqrt{\text{var}(X) \cdot \text{var}(Y)}$$

La quantité $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ est appelée *Somme des Carrés Résiduelle* ($SC_{\text{rés}}$).

Interprétation à l'aide de la droite des moindres carrés (D)

La quantité

$$\sum_{i=1}^n (y_i - \bar{y})^2$$

étant appelée *Somme des Carrés Totale*

$$(SC_{\text{tot}})$$

de Y , il s'ensuit :

$$1 - r^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{SC_{\text{rés}}}{SC_{\text{tot}}}$$

Interprétation à l'aide de la droite des moindres carrés (D)

$$SC_{\text{tot}} = SC_{\text{rés}} + SC_{\text{expl}}$$

avec :

$$SC_{\text{expl}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

Une autre interprétation de r^2 , complémentaire à celle de $(1 - r^2)$:

$$r^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{SC_{\text{expl}}}{SC_{\text{tot}}}$$

Régression de X sur Y :

$$x - \bar{x} = \frac{\text{cov}(X, Y)}{\text{var}(Y)}(y - \bar{y})$$

$$\implies y - \bar{y} = \frac{\text{var}(Y)}{\text{cov}(X, Y)}(x - \bar{x})$$

- ▶ Les distances sont mesurées parallèlement à l'axe des abscisses.
- ▶ Cette droite permet de prévoir X à partir de Y .
- ▶ Si X représente le temps, seule la régression de Y sur X a généralement un sens.

Somme des Carrés Résiduelle de la droite inverse

Le coefficient r étant symétrique par rapport à X et Y :

$$\sum_{i=1}^n |M_i G_i|^2 = \sum_{i=1}^n (x_i - \hat{x}_i)^2 = n \operatorname{var}(X)(1 - r^2)$$

- ▶ $(x_i - \hat{x}_i)$ représente l'erreur de prédiction sur X .
- ▶ Cette somme mesure la variabilité non expliquée par la droite inverse.
- ▶ Plus r^2 est proche de 1, plus les points sont proches de la droite.

Exemple : Droite de régression $D_{Y/X}$

$$a = \frac{\text{Cov}(X, Y)}{V(X)}$$

$$V(X) = \frac{1}{N} \sum_{i=1}^{10} x_i^2 - \bar{x}^2$$

$$= \frac{202}{10} - 4^2$$

$$= 4.2$$

$$a = \frac{15.5}{4.2} = 3.69$$

$$b = \bar{y} - a\bar{x}$$

$$= 52.9 - 3.69 \times 4$$

$$= 38.14$$

$Y = 3.69X + 38.14$

S	X	Y	XY	X ²	Y ²
1	2	50	100	4	2500
2	5	57	285	25	3249
3	1	41	41	1	1681
4	6	54	324	36	2916
5	5	54	270	25	2916
6	1	38	38	1	1444
7	6	63	378	36	3969
8	3	48	144	9	2304
9	4	59	236	16	3481
10	7	65	455	49	4225
Total	40	529	2271	202	28685

Exemple : Droite de régression $D_{X/Y}$

$$a' = \frac{\text{Cov}(X, Y)}{V(Y)}$$

$$V(Y) = \frac{1}{N} \sum_{i=1}^{10} y_i^2 - \bar{y}^2$$

$$= 8.37^2 = 70.05$$

$$a' = \frac{15.5}{70.05} = 0.22$$

$$b' = \bar{x} - a'\bar{y}$$


$$= 4 - 0.22 \times 52.9$$

$$= -7.63$$

$$\boxed{X = 0.22Y - 7.63}$$

Exemple : Droite de régression $D_{X/Y}$

Droite de régression D_{XY}



Coefficient de détermination

- ▶ Mesurer l'intensité de la liaison linéaire entre les deux variables X et Y revient à mesurer l'angle entre les droites de régression :

$$D_{Y/X} : (Y = aX + b)$$

et

$$D_{X/Y} : (X = a'Y + b')$$

- ▶ Le produit $a \times a'$ donne une bonne indication de l'importance de cet angle, donc de l'intensité de la corrélation.



$$0 \leq a \times a' \leq 1$$

- ▶ Plus

$$a \times a' \rightarrow 1$$


plus la corrélation est forte.

- ▶ Le produit $a \times a'$ est appelé **coefficient de détermination**, noté ρ^2 .


Lien entre corrélation et droites de regression

Cas de liaison:

*Pas de liaison linéaire
Indépendance linéaire*



Liaison relative



*Liaison fonctionnelle
linéaire*

