

Statistique appliquée à la recherche scientifique

Formation doctorale

Pr. El Mahdi Mouloua

16 mai 2026

Introduction

Théorie d'échantillonnage

Théorie de l'estimation

Tests d'hypothèses

Mouloua El Mahdi

La **statistique inférentielle** est une branche de la statistique qui permet de tirer des conclusions sur une population à partir d'un échantillon.

- ▶ Tirer des conclusions concernant une population à partir des données observées sur un échantillon ;

Mouloua El Mahdi

- ▶ Tirer des conclusions concernant une population à partir des données observées sur un échantillon ;
- ▶ Généraliser les résultats obtenus sur un sous-ensemble d'individus à l'ensemble de la population d'intérêt ;

Mouloua El Mahdji

- ▶ Tirer des conclusions concernant une population à partir des données observées sur un échantillon ;
- ▶ Généraliser les résultats obtenus sur un sous-ensemble d'individus à l'ensemble de la population d'intérêt ;
- ▶ Formuler des prédictions sur les caractéristiques ou le comportement de la population ;

- ▶ Tirer des conclusions concernant une population à partir des données observées sur un échantillon ;
- ▶ Généraliser les résultats obtenus sur un sous-ensemble d'individus à l'ensemble de la population d'intérêt ;
- ▶ Formuler des prédictions sur les caractéristiques ou le comportement de la population ;
- ▶ Évaluer si les différences, relations ou effets observés sont réels ou simplement dus au hasard d'échantillonnage ;

- ▶ Tirer des conclusions concernant une population à partir des données observées sur un échantillon ;
- ▶ Généraliser les résultats obtenus sur un sous-ensemble d'individus à l'ensemble de la population d'intérêt ;
- ▶ Formuler des prédictions sur les caractéristiques ou le comportement de la population ;
- ▶ Évaluer si les différences, relations ou effets observés sont réels ou simplement dus au hasard d'échantillonnage ;
- ▶ Quantifier l'incertitude associée aux conclusions statistiques ;

- ▶ Tirer des conclusions concernant une population à partir des données observées sur un échantillon ;
- ▶ Généraliser les résultats obtenus sur un sous-ensemble d'individus à l'ensemble de la population d'intérêt ;
- ▶ Formuler des prédictions sur les caractéristiques ou le comportement de la population ;
- ▶ Évaluer si les différences, relations ou effets observés sont réels ou simplement dus au hasard d'échantillonnage ;
- ▶ Quantifier l'incertitude associée aux conclusions statistiques ;
- ▶ Fournir un cadre rigoureux pour la prise de décision scientifique.

Motivation

La prédiction des résultats des élections.

Supposons qu'un pays compte 10 millions d'électeurs. Il est impossible, en pratique, d'interroger chaque électeur avant l'élection.

Le sondeur sélectionne alors un **échantillon représentatif** de taille $n = 1000$ électeurs.

Après le sondage, il obtient les résultats suivantes :

Candidat	Nombre de réponses	Proportion
A	540	54%
B	460	46%

Question :

Peut-on utiliser ces résultats pour tirer des conclusions sur l'ensemble des 10 millions d'électeurs ? À partir de l'échantillon observé, plusieurs questions se posent :

- ▶ Que peut-on conclure sur l'ensemble des 10 millions d'électeurs ?
- ▶ Les 54% observés reflètent-ils réellement l'opinion de la population ?
- ▶ Peut-on prédire le vainqueur de l'élection à partir du sondage ?

Quel est le paramètre recherché ?

Le sondage indique que :

$$\hat{p} = \frac{54}{1000} = 0.54$$

où :

- ▶ $\hat{p}$ est la proportion observée dans l'échantillon ;
- ▶ $\hat{p}$ est appelée une statistique d'échantillon.

Cependant, ce qui nous intéresse réellement est : p .

la proportion réelle d'électeurs soutenant le candidat A dans toute la population.

Question Les 54% observés correspondent-ils exactement à la valeur de p ?

Pourquoi devons-nous estimer ?

Supposons que plusieurs instituts réalisent des sondages indépendants.

Sondage	Proportion observée
1	54%
2	52%
3	56%
4	53%

Les résultats changent d'un échantillon à l'autre.

- La valeur observée $\hat{p}$ dépend de l'échantillon sélectionné.
- Nous utilisons donc $\hat{p}$ pour estimer le paramètre inconnu p .

Une estimation ponctuelle

$$\hat{p} = 0.54$$

ne renseigne pas sur sa précision.

Nous construisons alors un intervalle de confiance :

$$IC_{95\%}(p) = [50.9\%, 57.1\%]$$

Les données suggèrent que la proportion réelle d'électeurs favorables au candidat A se situe probablement entre 50.9% et 57.1%.

Comme tout l'intervalle est supérieur à 50%, le candidat A semble être favori.

Synthèse

Population $\implies$ Paramètre $p \implies$ Échantillon $\implies \hat{p} \implies IC_{95\%} \implies$ Décision

La statistique inférentielle permet de tirer des conclusions sur une population à partir d'un échantillon tout en quantifiant l'incertitude associée à ces conclusions.

La **population** n'est pas toujours donnée naturellement ; elle doit être définie rigoureusement par le chercheur.

Supposons que votre question de recherche soit :

Quel est l'effet du tabagisme sur le risque de maladie cardiovasculaire ?

La première difficulté n'est pas statistique mais conceptuelle : Qu'est-ce qu'un fumeur ?

1. Selon la définition retenue, la population étudiée change.
2. Les conclusions que vous allez tirer dépendent directement de la population définie.

Les critères d'éligibilité.

En théorie de l'échantillonnage, il convient de définir des **critères d'éligibilité** permettant de préciser quels individus appartiennent à la population cible et lesquels en sont exclus. Cette étape est essentielle, notamment dans le domaine médical, où le choix des patients à inclure dans l'étude dépend étroitement des objectifs et des questions de recherche considérés.

On distingue deux types d'échantillon issue d'une population :

1. Echantillon non probabiliste.
2. Echantillon probabiliste.

Théorie d'échantillonnage

Echantillonnage non probabiliste

L'échantillonnage non probabiliste désigne une méthode de sélection des individus d'une population fondée sur des critères prédéfinis, sans recours au hasard.

Exemples :

Échantillonnage restreint : sélection limitée aux unités facilement accessibles.

- Exemple : seuls les patients d'un même hôpital sont étudiés.

Échantillonnage par jugement : choix basé sur l'expertise du chercheur.

- Exemple : étude de certains types de tumeurs cérébrales jugés représentatifs.

Échantillonnage de convenance : sélection des individus les plus faciles à atteindre.

- Exemple : enquête réalisée auprès des personnes disponibles sur place.

Échantillonnage par quotas : chaque enquêteur collecte un nombre fixé d'unités ayant des caractéristiques données.

- Exemple : chaque chimiste fournit un nombre déterminé d'échantillons chimiques.

Théorie d'échantillonnage

Étapes de l'échantillonnage non probabiliste

1. Définir la population

- ▶ Identifier les individus ou objets à étudier.
- ▶ Une liste exhaustive n'est pas nécessaire ; seuls des critères d'éligibilité sont requis.

2. Choisir la méthode d'échantillonnage

- ▶ Sélectionner la technique adaptée aux objectifs de l'étude.
- ▶ Exemples : convenance, jugement, quotas, etc.

3. Déterminer la taille de l'échantillon

- ▶ Fixer le nombre d'unités à étudier.
- ▶ Ce choix dépend du temps, du budget et des ressources disponibles.

4. Sélectionner les participants

- ▶ Recruter les individus ou collecter les objets selon la méthode retenue.

5. Collecter les données

- ▶ Réaliser les enquêtes, observations, mesures ou entretiens nécessaires.

Théorie d'échantillonnage

Limites de la méthode d'échantillonnage non probabiliste

Remarque : cette approche est souvent pratique, mais peut contenir des limites :

1. Biais de sélection.
2. Manque de représentativité.
3. Généralisation limitée des résultats.
4. Impossibilité d'estimer rigoureusement l'erreur d'échantillonnage.

Exemple : Si une étude sur la satisfaction des patients est réalisée dans un seul hôpital, les résultats ne reflètent pas nécessairement l'opinion des patients de tous les hôpitaux.

Théorie d'échantillonnage

Echantillonnage probabiliste (aléatoire)

L'échantillonnage probabiliste repose sur un mécanisme de sélection aléatoire des unités statistiques à partir de la population cible. À chaque unité est associée une probabilité connue et non nulle d'inclusion dans l'échantillon. Cette approche vise à garantir l'objectivité du processus de sélection et à limiter les biais liés à l'intervention du chercheur. Lorsque la population est suffisamment importante et que son cadre d'échantillonnage est disponible, il est possible de tirer un échantillon aléatoire permettant d'effectuer des inférences statistiques valides sur l'ensemble de la population.

Théorie d'échantillonnage

Étapes de l'échantillonnage probabiliste

1. **Définition de la population** : Identifier l'ensemble des individus ou objets à étudier (par exemple, tous les étudiants d'une école ou tous les employés d'une entreprise), conformément à la question de recherche et aux hypothèses formulées.
2. **Établissement du cadre d'échantillonnage** : Constituer une liste complète des unités de la population, en attribuant à chacune un identifiant unique.
3. **Sélection aléatoire de l'échantillon** : Choisir les unités à l'aide d'une procédure aléatoire (générateur de nombres aléatoires, tirage au sort, etc.). La taille de l'échantillon dépend des objectifs de l'étude et des contraintes disponibles. Selon le plan d'échantillonnage adopté, les unités peuvent avoir des probabilités de sélection identiques ou différentes.
4. **Collecte des données** : Recueillir les informations auprès des unités sélectionnées. La taille de l'échantillon est généralement déterminée en fonction des besoins de l'étude et des ressources disponibles ; par exemple, lorsque la collecte des données est coûteuse, un échantillon plus restreint peut être retenu.

Théorie d'échantillonnage

Echantillonnage probabiliste (aléatoire)

- Les probabilités de sélection peuvent être égales ou différentes selon les objectifs de l'étude.
- L'échantillonnage probabiliste nécessite un cadre d'échantillonnage, c'est-à-dire une liste complète de la population.
- La construction de cette liste constitue souvent la principale difficulté pratique de cette méthode.

Théorie d'échantillonnage

Population stratifiée (Stratified Population)

Une population est dite **stratifiée** lorsqu'elle est divisée en plusieurs groupes homogènes appelés **strates** (*strata*).

Caractéristiques

1. Chaque individu appartient à une seule strate.
2. Les strates sont mutuellement exclusives ((un individu appartient à une seule strate).
3. Les strates couvrent toute la population.
4. Les individus d'une même strate sont relativement similaires.

Exemple

- ▶ Licence
- ▶ Master
- ▶ Doctorat

Théorie d'échantillonnage

Population regroupée en grappes(Clustered Population)

Une population est dite **clusterisée** lorsqu'elle est divisée en sous-groupes naturels appelés **grappes** (*clusters*).

Caractéristiques

1. Chaque grappe est une mini-population.
2. Les individus d'une même grappe sont variés.
3. Les grappes sont souvent définies géographiquement ou organisationnellement.

Exemple

- ▶ Classe A
- ▶ Classe B
- ▶ Classe C

Théorie d'échantillonnage

Echantillonnage probabiliste avec remise

Dans l'échantillonnage avec remise, chaque élément choisi est réintroduit dans la population avant le tirage suivant. Ainsi, la probabilité de sélection reste identique à chaque étape et un même individu peut être tiré plusieurs fois.

Cette technique est largement employée dans les procédures de simulation et de bootstrap, qui nécessitent la création répétée d'échantillons à partir des mêmes données afin d'étudier la variabilité ou la distribution d'un estimateur.

Théorie d'échantillonnage

Avantages et inconvénients de l'échantillonnage avec remise

Avantages	Inconvénients
Les tirages sont indépendants, ce qui facilite les analyses théoriques, les simulations et les procédures de rééchantillonnage.	Un même individu peut être sélectionné plusieurs fois, entraînant la présence de doublons dans l'échantillon.
La taille de l'échantillon peut dépasser celle de la population, offrant davantage de flexibilité dans les études statistiques.	Les répétitions réduisent la diversité des observations et peuvent diminuer la qualité de l'information collectée.
Cette approche est particulièrement adaptée aux petites populations et aux méthodes comme le bootstrap.	Si les doublons ne sont pas correctement pris en compte, les estimations des paramètres peuvent être biaisées.
	Dans le cas de populations vastes et hétérogènes, l'échantillon obtenu peut être moins représentatif de la population cible.

Théorie d'échantillonnage

Echantillonnage probabiliste sans remise

- Dans cette approche, une fois qu'on choisit un élément de la population pour former un échantillon, il ne peut pas être choisi autre fois. - Cette méthode permet à tous les éléments de la population d'avoir une chance de participer à l'échantillon, tout en assurant qu'aucun élément ne puisse être tiré ou retenu plusieurs fois. - On recourt généralement à cette approche lorsque le protocole de recherche nécessite que chaque unité statistique n'apparaisse qu'une seule fois dans l'échantillon, afin de préserver la validité de l'analyse.

Théorie d'échantillonnage

Avantages et inconvénients de l'échantillonnage sans remise

Avantages	Inconvénients
Aucune unité ne peut être sélectionnée plusieurs fois, ce qui élimine les doublons.	Nécessite une liste complète de la population avant le tirage.
Favorise une meilleure diversité et représentativité de l'échantillon.	Peut être difficile à appliquer aux populations très grandes ou évolutives.
La taille de l'échantillon est naturellement limitée à celle de la population.	Le suivi des unités déjà tirées peut accroître la complexité de la procédure.

Téorie d'échantillonnage

Échantillon d'individus et échantillon de valeurs

- On considère un sous-ensemble de cardinal n issu d'une population de taille finie ou infinie, sélectionné selon certaines règles ou certains critères. On parle alors d'un **échantillon d'individus**.
 - On considère ensuite un **échantillon de valeurs** associé à cet échantillon d'individus.
-
- ▶ **Population finie** : les 12 000 patients atteints de diabète suivis dans un hôpital.
 - ▶ **Population infinie** : toutes les mesures de glycémie susceptibles d'être observées chez les futurs patients provenant du même processus biologique.

Pour chaque individu sélectionné, on mesure une variable X et l'on note $x_1, \dots, x_n$ les valeurs observées. Le n -uplet $\mathbf{x} = (x_1, \dots, x_n)$ est appelé un **échantillon de valeurs**.

Théorie d'échantillonnage

Atelier

Atelier sur la théorie de l'échantillonnage avec python.

Mouloua El Mahdi

Théorie d'échantillonnage

Échantillon d'individus et échantillon de valeurs

Définition.

Les variables aléatoires $X_1, \dots, X_n$ forment un **échantillon de taille n** (ou **n -échantillon**) d'une population de loi P_X si les variables aléatoires $X_1, \dots, X_n$ sont **indépendantes et identiquement distribuées** (i.i.d.) comme la variable aléatoire X de loi P_X .

La variable X est appelée la variable parente de la population.

Théorie de l'échantillonnage

Densité conjointe de n-uplet $(X_1, \dots, X_n)$

Dans le cas continu :

$$f(x_1, \dots, x_n) = f_{X_1}(x_1)f_{X_2}(x_2) \cdots f_{X_n}(x_n) = \prod_{i=1}^n f_{X_i}(x_i)$$

Dans le cas discret :

$$P(x_1, \dots, x_n) = P(X_1 = x_1)P(X_2 = x_2) \cdots P(X_n = x_n) = \prod_{i=1}^n P(X_i = x_i)$$

Cette densité conjointe permet de calculer diverses probabilités relatives à l'échantillon $(X_1, \dots, X_n)$.

Théorie de l'échantillonnage

Population paramétrique

Soit un échantillon aléatoire

$$(X_1, \dots, X_n)$$

issu d'une population dont la loi dépend d'un paramètre inconnu

$$\theta \in \Theta.$$

La densité (ou fonction de masse) de probabilité de chaque observation est notée

$$f_{\theta}(x).$$

Comme les variables $X_1, \dots, X_n$ sont supposées indépendantes et identiquement distribuées (i.i.d.), la densité conjointe du n-échantillon est

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f_{\theta}(x_i).$$

Le paramètre θ est inconnu et caractérise la population étudiée. L'objectif principal de l'inférence statistique est d'estimer sa valeur à partir de l'échantillon observé.

Théorie de l'échantillonnage

Exemple

Soit un n -échantillon

$$X_1, \dots, X_n$$

représentant les durées de fonctionnement (en mois) de n ampoules issues d'une population exponentielle de paramètre β .

Comme les variables sont i.i.d., la densité conjointe est

$$f(x_1, \dots, x_n) = \prod_{i=1}^n f_{\beta}(x_i) = \prod_{i=1}^n \frac{1}{\beta} e^{-x_i/\beta}, \quad x_i \geq 0.$$

Question :

Quelle est la probabilité que toutes les ampoules aient une durée de fonctionnement d'au moins 2 mois ?

$$P(X_1 > 2, \dots, X_n > 2)$$

Théorie de l'échantillonnage

Exemple

Par indépendance,

$$P(X_1 > 2, \dots, X_n > 2) = \prod_{i=1}^n P(X_i > 2).$$

Comme les variables ont la même loi,

$$P(X_1 > 2, \dots, X_n > 2) = \left(P(X_1 > 2)\right)^n.$$

Or, pour une loi exponentielle de paramètre β ,

$$P(X_1 > 2) = e^{-2/\beta}.$$

Ainsi,

$$P(X_1 > 2, \dots, X_n > 2) = e^{-2n/\beta}.$$

1. Le modèle d'échantillonnage décrit dans la Définition 1 est également appelé **échantillonnage à partir d'une population infinie**.
2. **Échantillonnage d'une population finie** : dans ce cas, les hypothèses d'indépendance peuvent ne pas être vérifiées, selon que le tirage est effectué avec ou sans remise.

Théorie de l'échantillonnage

Exemple (1/2)

On considère la population

$$P = \{1, \dots, 1000\},$$

de taille $N = 1000$. On tire sans remise un échantillon de taille $n = 10$.

Calculons la probabilité que les 10 valeurs sélectionnées soient strictement supérieures à 200.

Approximation par indépendance

Les valeurs strictement supérieures à 200 sont au nombre de

$$1000 - 200 = 800.$$

Ainsi,

$$P(X_i > 200) = \frac{800}{1000} = 0.8.$$

Sous l'hypothèse d'indépendance,

$$P(X_1 > 200, \dots, X_{10} > 200) = \prod_{i=1}^{10} P(X_i > 200) = (0.8)^{10}.$$

Par conséquent,

$$P(X_1 > 200, \dots, X_{10} > 200) = 0.107374.$$

Théorie de l'échantillonnage

Exemple (2/2)

Calcul exact

Soit : $Z = \#\{X_i > 200\}$

le nombre de valeurs strictement supérieures à 200 dans l'échantillon.

Comme le tirage est effectué sans remise,

$$Z \sim \mathcal{H}(N = 1000, K = 800, n = 10),$$

où

- ▶ $N = 1000$: taille de la population ;
- ▶ $K = 800$: nombre de succès ($X_i > 200$) ;
- ▶ $n = 10$: taille de l'échantillon.

La probabilité recherchée est

$$P(Z = 10) = \frac{\binom{800}{10} \binom{200}{0}}{\binom{1000}{10}} \simeq 0.106164.$$

On remarque que cette probabilité est très proche de celle obtenue sous l'hypothèse d'indépendance :

$$0.106164 \approx 0.107374.$$

L'approximation par indépendance est donc très satisfaisante lorsque la taille de la population est grande devant celle de l'échantillon.

Théorie de l'échantillonnage

Variable d'échantillonnage

En pratique, les n observations $x_1, \dots, x_n$ sont souvent résumées par quelques caractéristiques simples telles que la moyenne, la variance, l'étendue ou encore le maximum.

Ces caractéristiques sont elles-mêmes des réalisations de variables aléatoires définies à partir de l'échantillon aléatoire $(X_1, \dots, X_n)$.

Définition.

On appelle *variable d'échantillonnage* ou *statistique* toute variable aléatoire T qui est une fonction de l'échantillon :

$$T = g(X_1, \dots, X_n).$$

La loi de probabilité de T est appelée **distribution échantillonnale** de T .

Remarques

- ▶ Une statistique ne doit pas dépendre d'un paramètre inconnu.
- ▶ Les statistiques sont généralement notées par des lettres majuscules $(T, \bar{X}, S^2, \dots)$ et leurs réalisations par des lettres minuscules $(t, \bar{x}, s^2, \dots)$.

Théorie de l'échantillonnage

Statistiques usuelles

1. Moyenne d'échantillonnage (moyenne empirique)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

2. Variance empirique

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

3. Variance corrigée d'échantillonnage

$$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

4. Écart-type d'échantillonnage

$$S_{n-1} = \sqrt{S_{n-1}^2}.$$

Théorie de l'échantillonnage

Théorème Central Limite

Soient

$$X_1, \dots, X_n$$

des variables aléatoires indépendantes et identiquement distribuées telles que

$$\mathbb{E}(X_i) = \mu, \quad \text{Var}(X_i) = \sigma^2 < +\infty.$$

Alors, lorsque $n \rightarrow +\infty$,

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Autrement dit, pour n suffisamment grand,

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Théorie de l'échantillonnage

Interprétation du TCL

Le Théorème Central Limite affirme que la moyenne empirique

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

admet une distribution approximativement normale lorsque la taille de l'échantillon devient grande.

Cette propriété est remarquable car elle est vérifiée quelle que soit la distribution initiale des observations, à condition que leur variance soit finie.

Ainsi, des données issues de lois exponentielles, uniformes, binomiales ou de nombreuses autres distributions conduisent à une moyenne empirique approximativement gaussienne.

Théorie de l'échantillonnage

Rôle en inférence statistique

Le TCL constitue le fondement théorique de nombreuses méthodes d'inférence statistique.

1. Construction des intervalles de confiance.
2. Réalisation des tests d'hypothèses.
3. Quantification de l'incertitude associée aux estimations.
4. Approximation de la distribution de nombreuses statistiques.

Sans le TCL, la plupart des méthodes statistiques modernes seraient difficiles à appliquer lorsque la distribution de la population est inconnue.

Théorie de l'échantillonnage

Applications scientifiques

Le Théorème Central Limite intervient dans de nombreux domaines :

- ▶ Physique expérimentale ;
- ▶ Biologie et médecine ;
- ▶ Économie et finance ;
- ▶ Sciences sociales ;
- ▶ Intelligence artificielle et apprentissage automatique ;
- ▶ Fiabilité et ingénierie.

Il explique notamment pourquoi la loi normale apparaît très fréquemment dans l'analyse des phénomènes naturels et des erreurs de mesure.

Le TCL est ainsi considéré comme l'un des résultats les plus importants de la statistique moderne.

Théorie de l'estimation

Motivation

Une machine fabrique des pièces.

Chaque pièce a une probabilité inconnue θ d'être défectueuse.

On prélève un échantillon de n pièces et on observe :

X = nombre de pièces défectueuses.

Deux questions se posent naturellement :

1. Quelle est la valeur probable de θ ?
2. Peut-on garantir que θ reste inférieure à un seuil acceptable ?

Théorie de l'estimation

Estimation ponctuelle

Supposons que :

$$n = 200, \quad X = 12.$$

La proportion observée de pièces défectueuses est

$$\hat{\theta} = \frac{X}{n} = \frac{12}{200} = 0.06.$$

Théorie de l'estimation

Estimation ponctuelle

Supposons que :

$$n = 200, \quad X = 12.$$

La proportion observée de pièces défectueuses est

$$\hat{\theta} = \frac{X}{n} = \frac{12}{200} = 0.06.$$

Estimation ponctuelle

L'estimateur naturel de θ est

$$\hat{\theta} = \frac{X}{n}.$$

On estime donc que la proportion réelle de pièces défectueuses est d'environ 6%.

Théorie de l'estimation

Estimation ponctuelle

L'estimation observée est

$$\hat{\theta} = 0.06.$$

Mais la vraie valeur de θ est inconnue.

Question importante

La vraie valeur est-elle exactement égale à 0.06 ?

Théorie de l'estimation

Estimation ponctuelle

L'estimation observée est

$$\hat{\theta} = 0.06.$$

Mais la vraie valeur de θ est inconnue.

Question importante

La vraie valeur est-elle exactement égale à 0.06 ?

La réponse est généralement non.

Un autre échantillon aurait produit une valeur différente.

0.05, 0.07, 0.04, 0.08, ...

Il faut donc quantifier **l'incertitude** associée à l'estimation.

Simulation Python

Supposons que la vraie proportion soit $\theta = 0.06$.

Nous répétons l'expérience 1000 fois.

```
import numpy as np

theta = 0.06
n = 200

estimations = []

for _ in range(1000):
    X = np.random.binomial(n, theta)
    estimations.append(X/n)

print(np.mean(estimations))
```


```
import matplotlib.pyplot as plt

plt.hist(estimations, bins=20)
plt.xlabel("Estimation")
plt.ylabel("Fréquence")
plt.show()
```

Les estimations fluctuent autour de la vraie valeur $\theta = 0.06$. Cette variabilité est due à l'échantillonnage.

Théorie d'estimation

Estimation ponctuelle



- Les estimations obtenues sont différentes d'un échantillon à l'autre.
- Elles restent concentrées autour de la vraie valeur $\theta = 0.06$.
- L'estimateur $\hat{\theta} = X/n$ est donc une variable aléatoire.
- Sa variabilité provient de l'échantillonnage.

Définition

Soit $X_1, \dots, X_n$ un échantillon aléatoire simple relatif à la variable aléatoire parente X dont la loi dépend du paramètre θ .

On appelle **estimateur** du paramètre θ toute statistique

$$\hat{\theta} = g(X_1, \dots, X_n)$$

utilisée dans le but d'approcher la valeur inconnue de θ .

Théorie d'estimation

Principales méthodes d'estimation

1. Méthode des moments
2. Maximum de vraisemblance
3. Moindres carrés
4. Estimation bayésienne
5. Bootstrap
6. GMM
7. M-estimation
8. Méthodes du minimum de distance
9. Estimation à noyau
10. MCMC

Méthode des Moments

1. Soit $X = (X_1, \dots, X_n)$ un échantillon aléatoire issu d'une distribution dépendant de k paramètres inconnus $\theta_1, \dots, \theta_k$.
2. Supposons que les k premiers moments théoriques existent : $E(X^j), j = 1, \dots, k$.
3. Les moments empiriques correspondants sont définis par
$$m_j = \frac{1}{n} \sum_{i=1}^n X_i^j, \quad j = 1, \dots, k.$$
4. Supposons que les moments théoriques puissent s'écrire sous la forme
$$E(X^j) = h_j(\theta_1, \dots, \theta_k), \quad j = 1, \dots, k.$$

Méthode des Moments

On remplace ensuite les moments théoriques $E[X^j]$ par leurs estimateurs empiriques respectifs m_j , puis on résout le système :

$$\begin{cases} m_1 = h_1(\theta_1, \dots, \theta_k), \\ m_2 = h_2(\theta_1, \dots, \theta_k), \\ \vdots \\ m_k = h_k(\theta_1, \dots, \theta_k). \end{cases}$$

Les k solutions $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ de ce système constituent les estimateurs des k paramètres $\theta_1, \dots, \theta_k$.

Méthode des moments

Exemple

Soit $\theta = (\mu, \sigma^2)$ le paramètre à estimer, où μ est la moyenne et σ^2 la variance de la variable aléatoire X .

Les moments échantillonnaux sont $m_1 = \bar{X}$ et $m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$.

Les deux premiers moments théoriques sont $E[X] = \mu$ et $E[X^2] = \mu^2 + \sigma^2$.

Le système à résoudre est :

$$m_1 = \bar{X} = \mu$$

$$m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 = \mu^2 + \sigma^2$$

Ainsi, les estimateurs de moments sont

$$\hat{\mu}_{MM} = \bar{X}$$

et

$$\widehat{\sigma^2}_{MM} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Méthode du maximum de vraisemblance

On dispose d'un échantillon

$$X_1, \dots, X_n \sim f(x; \theta)$$

où θ est inconnu.

Question :

Quelle valeur de θ explique le mieux les données observées ?

L'idée est de comparer plusieurs valeurs possibles de θ et de retenir celle qui rend l'échantillon observé le plus plausible.

Méthode du maximum de vraisemblance

Supposons que

$$X_1, \dots, X_n \sim f(x; \theta),$$

où θ est inconnu.

Après l'expérience, on observe

$$x_1, \dots, x_n.$$

Pour chaque valeur possible de θ , on calcule

$$f(x_1, \dots, x_n; \theta).$$

Comme les observations sont fixées, on définit

$$L(\theta) = f(x_1, \dots, x_n; \theta).$$

Cette fonction est appelée fonction de vraisemblance.

Méthode du maximum de vraisemblance

Soit $X = (X_1, \dots, X_n)$ un n -échantillon de loi inconnue appartenant à une famille de lois paramétriques de paramètre $\theta = (\theta_1, \dots, \theta_k)$, et soit $(x_1, \dots, x_n)$ la valeur observée correspondante.

La méthode du maximum de vraisemblance (M.V.) consiste à estimer le paramètre θ par la valeur $\hat{\theta} = \hat{\theta}(x)$ qui rend maximale la fonction de vraisemblance $L(x, \theta)$.

Remarque :

Pour déterminer $\hat{\theta}$, il est souvent commode d'utiliser $\log[L(x, \theta)]$ car cette dernière fonction atteint son maximum au même point que la fonction $L(\theta)$.

Méthode du maximum de vraisemblance

Exemple (Contrôle de qualité par sondage)

Une machine fabrique une proportion θ inconnue de pièces défectueuses. On souhaite estimer θ .

On prélève n pièces avec remise et on observe les variables aléatoires $X_1, \dots, X_n$, où $X_i = 1$ si la pièce est défectueuse et 0 sinon.

Méthode de vraisemblance

Exemple (Suite)

Les variables $X_1, \dots, X_n$ sont indépendantes et suivent la loi $\mathcal{B}(\theta)$.

La fonction de vraisemblance est

$$L(x, \theta) = P_\theta(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}.$$

La log-vraisemblance vaut

$$\ell(\theta) = \log L(x, \theta) = \left(\sum_{i=1}^n x_i\right) \log \theta + \left(n - \sum_{i=1}^n x_i\right) \log(1 - \theta).$$

En annulant la dérivée :

$$\frac{\sum_{i=1}^n x_i}{\theta} - \frac{n - \sum_{i=1}^n x_i}{1 - \theta} = 0.$$

On obtient alors

$$\hat{\theta}_{MV} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{X}.$$

L'erreur Moyenne quadratique

Soit $X = (X_1, \dots, X_n)$ un n -échantillon de loi appartenant à une famille paramétrique de paramètre $\theta = (\theta_1, \dots, \theta_k)$.

Soit $T = T(X)$ un estimateur de la quantité $g(\theta)$.

L'erreur moyenne quadratique (EMQ) de l'estimateur T est définie par

$$R(\theta, T) = E_{\theta} \left[(T - g(\theta))^2 \right].$$

Elle mesure l'écart moyen entre l'estimateur T et la quantité inconnue $g(\theta)$ que l'on cherche à estimer.

Ici, E_{θ} désigne l'espérance mathématique relativement à la loi P_{θ} .

Théorie d'estimation

Propriétés d'un estimateur

L'erreur moyenne quadratique peut s'exprimer à l'aide de la variance et du biais de l'estimateur.

On a :

$$R(\theta, T) = \text{Var}(T) + b^2(\theta, T),$$

où

$$b(\theta, T) = E(T) - g(\theta).$$

La quantité $b(\theta, T)$ est appelée **biais** de l'estimateur T .

Ainsi, l'erreur moyenne quadratique dépend de deux composantes :

- ▶ la variance de l'estimateur ;
- ▶ le carré de son biais.

Comparaison de deux estimateurs

En pratique, plusieurs estimateurs peuvent être proposés pour estimer une même quantité $g(\theta)$.

La question fondamentale est alors :

Quel estimateur faut-il choisir ?

Pour répondre à cette question, on évalue la qualité de chaque estimateur à l'aide de son **risque quadratique** $R(\theta, T)$.

Plus le risque quadratique est faible, plus l'estimateur est précis.

Théorie de l'estimation

Propriétés d'un estimateur

Comparaison de deux estimateurs

Soient $T = T(X)$ et $S = S(X)$ deux estimateurs de $g(\theta)$.

On dit que T est **meilleur que** S (au sens du risque quadratique) si

$$R(\theta, T) \leq R(\theta, S), \quad \forall \theta \in \Theta.$$

On dit que T est **strictement meilleur** que S si

$$R(\theta, T) \leq R(\theta, S), \quad \forall \theta \in \Theta,$$

et

$$\exists \theta_0 \in \Theta \quad \text{tel que} \quad R(\theta_0, T) < R(\theta_0, S).$$

Comparaison de deux estimateurs

Exemple

Soit $(X_1, X_2, \dots, X_n)$ un n -échantillon de loi $N(\theta, 1)$.

1. On considère la moyenne échantionnale $T_1 = \bar{X}$, il s'agit un estimateur naturel de θ .

$$R(\theta, T_1) = \text{Var}(T_1) + b^2(\theta, T_1) = \text{Var}(T_1) = \frac{1}{n}$$

2. On Considère $T_2 = X_2$, on a $E(T_2) = \theta$ et ainsi

$$R(\theta, T_2) = \text{Var}(T_2) + b^2(\theta, T_2) = \text{Var}(T_2) = 1$$

T_1 est strictement meilleur que T_2 (si $n > 1$)

On appelle **estimateur sans biais** de $g(\theta)$ toute statistique $T = T(X)$ telle que :

$$b(\theta, T) = 0, \quad \forall \theta.$$

Exemples :

Soit $X = (X_1, \dots, X_n)$ un n -échantillon tel que

$$\mathbb{E}(X_i) = \mu \quad \text{et} \quad \text{Var}(X_i) = \sigma^2.$$

- ▶ $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ est un estimateur sans biais de μ .
- ▶ $S'^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ est un estimateur sans biais de σ^2 .
- ▶ $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ est un estimateur avec biais de σ^2 .
- ▶ $S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ est un estimateur sans biais de σ^2 .

Théorie d'estimation

Estimateur sans biais de variance minimum

Soit $\hat{\theta}$ un estimateur sans biais du paramètre θ , c'est-à-dire

$$\mathbb{E}_{\theta}[\hat{\theta}] = \theta, \quad \forall \theta \in \Theta.$$

On dit que $\hat{\theta}$ est un **estimateur sans biais de variance minimum** si, pour tout autre estimateur sans biais $\tilde{\theta}$ de θ , on a

$$\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}_{\theta}(\tilde{\theta}), \quad \forall \theta \in \Theta.$$

Autrement dit, parmi tous les estimateurs sans biais de θ , $\hat{\theta}$ possède la plus petite variance.

Théorie de l'estimation

Estimation ensembliste

Il est souvent plus pertinent de fournir un intervalle contenant une valeur plausible du paramètre inconnu θ plutôt que de proposer uniquement une estimation ponctuelle $\hat{\theta}$. Ainsi, au lieu d'écrire

$$\hat{\theta} = c,$$

on cherche à déterminer deux statistiques $\hat{\theta}_1$ et $\hat{\theta}_2$ telles que

$$\hat{\theta}_1 < \theta < \hat{\theta}_2.$$

L'intervalle

$$[\hat{\theta}_1, \hat{\theta}_2]$$

est appelé un **intervalle d'estimation** de θ . Cette approche constitue l'**estimation par intervalle** (ou **estimation ensembliste**).

Estimation ensembliste

Intervalle de confiance de niveau $1 - \alpha$

Un intervalle aléatoire

$$[\hat{\theta}_1, \hat{\theta}_2]$$

est appelé **intervalle de confiance de niveau $1 - \alpha$** si

$$\mathbb{P}(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 1 - \alpha.$$

La probabilité est calculée par rapport aux échantillons aléatoires, tandis que le paramètre θ est considéré comme une constante inconnue.

Interprétation

Un niveau de confiance $1 - \alpha$ signifie que si l'on répétait le prélèvement d'échantillons un grand nombre de fois, environ $100(1 - \alpha)\%$ des intervalles construits contiendraient la véritable valeur du paramètre θ .

Estimation ensembliste

Construction d'un intervalle de confiance

Pour construire un intervalle de confiance, on procède comme suit :

- ▶ On dispose d'une statistique (ou d'un estimateur) T du paramètre inconnu θ , dont la loi de probabilité est connue ou peut être déterminée.
- ▶ Pour une valeur fixée du paramètre, notée θ , on détermine deux constantes t_1 et t_2 telles que

$$\mathbb{P}_{\theta}(t_1 < T < t_2) = 1 - \alpha,$$

où $\alpha \in [0, 1]$ est fixé.

Estimation ensembliste

Intervalle de confiance pour la moyenne (σ connue)

On cherche un intervalle de confiance de niveau $1 - \alpha$ pour la moyenne μ , où

$$0 < \alpha < 1.$$

Définition de la α -fractile

Soit $Z \sim \mathcal{N}(0, 1)$ et Φ sa fonction de répartition.

On appelle z_α le réel vérifiant

$$1 - \Phi(z_\alpha) = P(Z > z_\alpha) = \alpha.$$

Compte tenu de la symétrie de la loi normale centrée réduite,

$$\begin{aligned} P(-z_{\alpha/2} < Z < z_{\alpha/2}) &= \Phi(z_{\alpha/2}) - \Phi(-z_{\alpha/2}) \\ &= \Phi(z_{\alpha/2}) - (1 - \Phi(z_{\alpha/2})) \\ &= \left(1 - \frac{\alpha}{2}\right) - \frac{\alpha}{2} \\ &= 1 - \alpha. \end{aligned}$$

$$P(-z_{\alpha/2} < Z < z_{\alpha/2}) = 1 - \alpha.$$

Estimation ensembliste

Intervalle de confiance pour la moyenne (σ connue)

Si $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, avec σ connue, alors

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Ainsi,

$$P\left(-z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_{\alpha/2}\right) = 1 - \alpha.$$

En multipliant par $\frac{\sigma}{\sqrt{n}}$,

$$P\left(-z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

En ajoutant μ puis en réorganisant les inégalités,

$$P\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

$$IC_{1-\alpha}(\mu) = \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

Estimation ensembliste

Exemple 1 : Intervalle de confiance pour une moyenne

On suppose que

$$X \sim \mathcal{N}(\mu, 4),$$

et que l'on dispose de

$$n = 9$$

observations :

$$5, 8.5, 12, 15, 7, 9, 7.5, 6.5, 10.5.$$

On obtient

$$\bar{X} = 9, \quad \sigma = 2.$$

Pour un niveau de confiance de 95%,

$$\alpha = 0.05, \quad z_{0.025} = 1.96.$$

Ainsi,

$$\begin{aligned} IC_{0.95}(\mu) &= \left[9 - 1.96 \frac{2}{\sqrt{9}}, 9 + 1.96 \frac{2}{\sqrt{9}} \right] \\ &= [7.69, 10.31]. \end{aligned}$$

Intervalle de confiance d'une proportion

Soient $X_1, \dots, X_n$ un échantillon i.i.d. de loi de Bernoulli de paramètre p .

L'estimateur de la proportion est

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i.$$

D'après le théorème central limite,

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Comme p est inconnu, on le remplace par son estimateur $\hat{p}$. On obtient l'intervalle de confiance asymptotique au niveau $1 - \alpha$

$$IC_{1-\alpha}(p) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right].$$

Validité :

$$n\hat{p} \geq 5 \quad \text{et} \quad n(1-\hat{p}) \geq 5.$$

Estimation ensembliste

Exemple 2 : Intervalle de confiance pour une proportion

Contexte :

Une municipalité souhaite estimer la proportion de déchets plastiques dans les déchets ménagers afin d'évaluer l'efficacité de sa politique de recyclage. Un échantillon aléatoire de $n = 500$ déchets est analysé.

Les résultats obtenus sont :

$$x = 185 \quad \Rightarrow \quad \hat{p} = \frac{185}{500} = 0.37.$$

L'intervalle de confiance à 95% de la proportion est donné par

$$IC_{95\%} = \left[\hat{p} - 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \hat{p} + 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right].$$

Après calcul,

$$IC_{95\%} = [0.328, 0.412].$$

Interprétation :

Avec un niveau de confiance de 95%, on estime que la proportion réelle de déchets plastiques

- ▶ Une **hypothèse statistique** est une affirmation formulée sur un ou plusieurs paramètres d'une population à partir d'un phénomène observé.
- ▶ Un **test d'hypothèse** permet de décider si cette affirmation est retenue ou rejetée à partir des données observées.
- ▶ Une **hypothèse simple** spécifie une valeur précise du paramètre.

$$H_0 : \theta = \theta_0.$$

- ▶ Une **hypothèse composée** regroupe plusieurs valeurs possibles du paramètre.

$$H_0 : \theta \leq \theta_0, \quad H_0 : \theta \geq \theta_0, \quad H_0 : \theta \in \Theta_0.$$

Tests d'hypothèses

Exemples

- (a) L'affirmation $Y \sim \mathcal{E}(\lambda)$ est une **hypothèse simple** si le paramètre λ est fixé. En revanche, " Y suit une loi exponentielle" est une **hypothèse composée**, car la valeur de λ n'est pas précisée.
- (b) Soit $Y \sim \mathcal{B}(n, p)$. Les hypothèses $H_0 : p \leq p_0$ et $H_0 : p = p_0$ sont respectivement une **hypothèse composée** et une **hypothèse simple**.
- (c) L'hypothèse
- X et Y suivent la même loi
- est une **hypothèse composée**, car elle ne spécifie pas entièrement la distribution commune.

Remarque

- Les hypothèses des exemples (a) et (b) sont des **hypothèses paramétriques**.
- L'hypothèse de l'exemple (c) est une **hypothèse non paramétrique**.

Tests d'hypothèses

Soient $X_1, \dots, X_n$ un échantillon aléatoire issu d'une loi P_θ et $x = (x_1, \dots, x_n)$ une réalisation de cet échantillon.

Un **test d'hypothèse** est une règle de décision qui, à partir des données observées, permet de décider si l'on **rejette** ou **ne rejette pas** une hypothèse portant sur le paramètre inconnu θ .

En pratique, la décision repose sur une **statistique de test**

$$T = T(X_1, \dots, X_n),$$

qui résume l'information contenue dans l'échantillon et dont la valeur est comparée à une région critique.

Exemple

On souhaite contrôler le taux moyen de polluants (en ppm) dans un procédé de fabrication. Si le seuil acceptable est de 75 ppm, on teste

$$H_0 : \mu = 75 \quad \text{contre} \quad H_1 : \mu > 75.$$